

Aprendizes II :


2. Conexionista :

↳ Ramo de A.I. inspirado no cérebro, que se foca em redes neuronais.

2.1. Conceitos :

- Encoding info.
- Neurónios interligados.
 - Aprendizagem a partir de dados.
 - Reconhecimento de padrões.
 - Processamento paralelo.
 - Taxa de disparo: Força do estímulo.
 - Tempo de disparo: Tempo preciso em que o estímulo é sent

Neurónio McCulloch-Pitts :



- Tem uma saída binária baseada numa ativação por limiar (θ).
- Consegue implementar operações lógicas básicas.

Input	x_1, x_2, \dots, x_n
Weights	w_1, w_2, \dots, w_n
Summation	$\Sigma(w_i x_i)$
Threshold	θ
Output	1 if $\Sigma(w_i x_i) \geq \theta$, else 0

2.2. Arquitetura / Funcionamento de Redes Neuronais.

2.2.1. Funções Ativação :

↳ introduzem a não-linearidade nas redes neuronais e determinam a saída do neurónio com base na entrada.

- Função degrau : saída binária, baseada em linear.
- Sigmoid : Curva suave em forma de "S" entre 0 e 1.
- ReLU : Linear para input positivo, 0 para negativo.

2.2.2. Rede Neuronal Artificial Simples:

- Camada Entrada : Recebe dados iniciais.
- Camada Oculta : Processa a info da camada entrada.
- Camada Saída : Produz o resultado final.

Como implementar:

- Step 1 {
 - (1) Definir Arquitetura: especificar n° de camadas e neurônios.
 - (2) Inicializar Pesos: definir valores random para os pesos.
 - (3) Escolher Ativação: selecionar funções de ativação.
- Step 2 {
 - (4) Passagem Direta: calcular saída para dada entrada.
 - (5) Calcular Erro: Comparar saída com o resultado desejado.
 - (6) Passagem Inversa: propagar erro + ajustar pesos.
- Step 3 {
 - (7) Iterar: repetir (4), (5) e (6)
 - (8) Monitorizar Desempenho: Acompanhar a redução do erro.
 - (9) Afinar: Ajustar hiperparâmetros para melhorar resultados.
 - (10) Avaliar: Testar a rede em dados não vistos.

2.2.3. Rede MLP (Multi-Layer Perceptron):

Redes Neurais com múltiplas camadas de perceptrons que podem aprender padrões complexos e não lineares.

- Camada Entrada: Mesmo que 2.2.2.
- Camadas Ocultas: Mesmo que 2.2.2. mas são várias
- Camada Saída: Mesmo que 2.2.2.

Nota: Aqui a Passagem Direta envolve:

- (1) Processamento de Entrada.
- (2) Aplicação de Pesos
- (3) Adição de Bias
- (4) Ativação $ans = f(ans)$
- (5) Propagação (output é input do próximo layer)
- (6) Final output!

$$ans = (input \times pesos) + bias$$

2.3. Aprendizagem e Redes Neurais:

↳ Processo iterativo impulsionado por dados, onde os pesos e polarizações são atualizados para minimizar o erro.

- Função de Custo: Quantifica o erro entre a saída prevista e a real.
- Gradient Descent: 1. calcular a derivada de erro em relação aos parâmetros.
2. Atualizar parâmetros (Bias, pesos)
3. Repetir!

otimizar os parâmetros na rede.

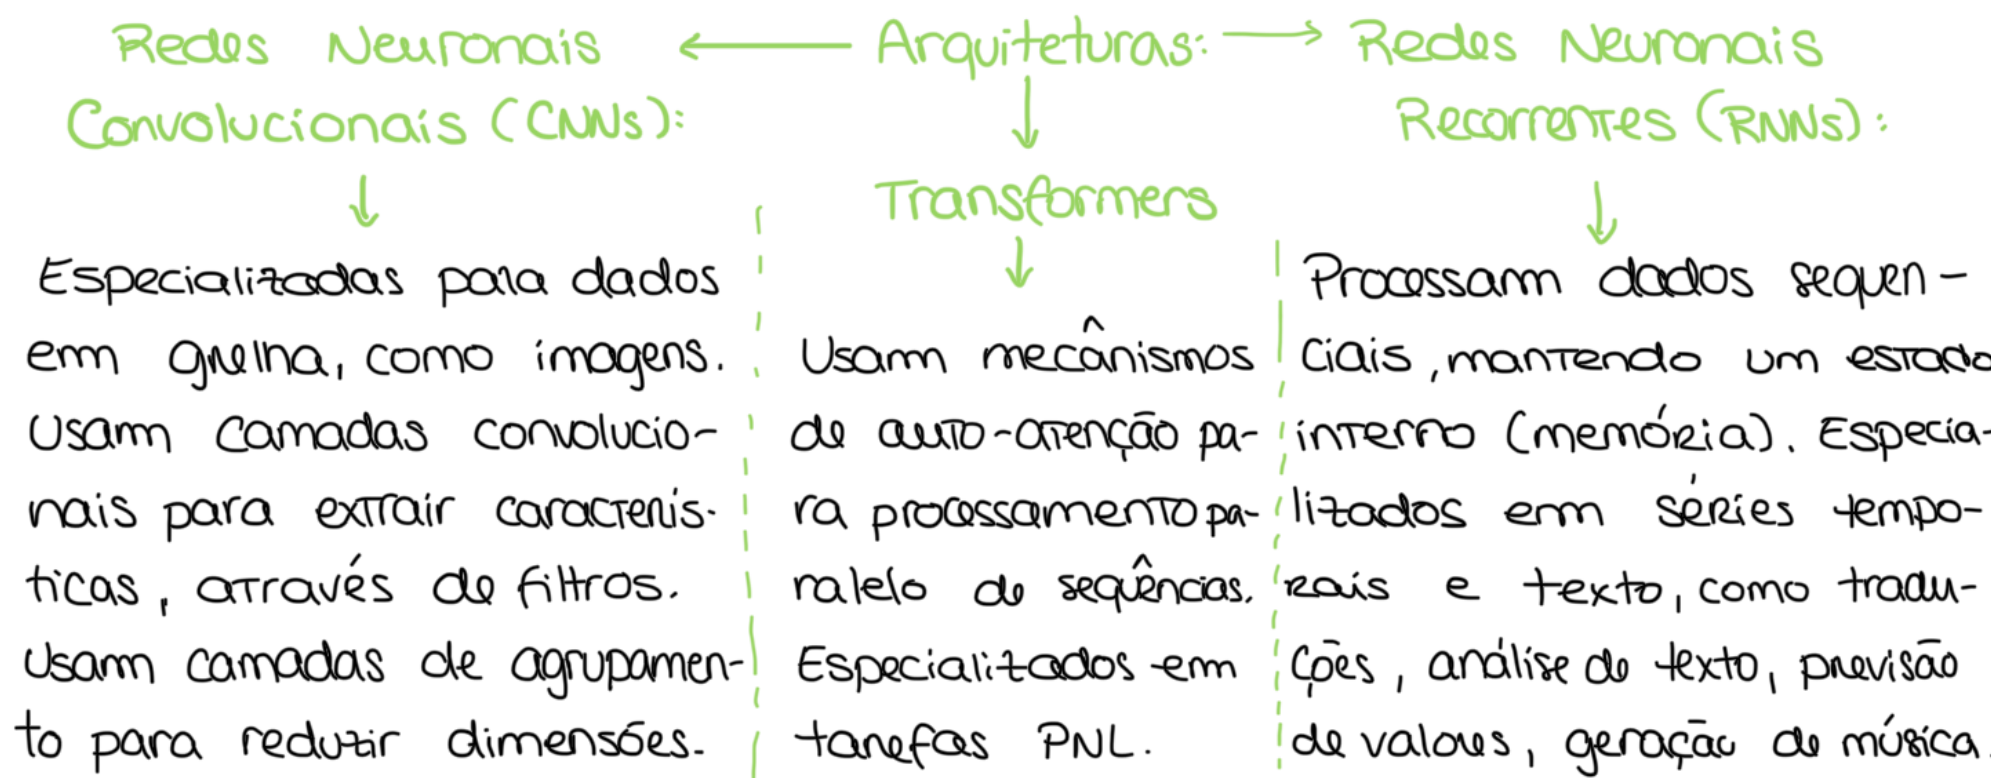
2.3.1. Algoritmo de Retropropagação (Backpropagation)

- (1) Cálculo do erro (entre saída e alvo).
- (2) Passagem inversa (propagar o erro da camada de saída para a de entrada).
- (3) Cálculo do gradiente (calcular derivadas parciais para cada parâmetro).
- (4) Atualizar Pesos.

2.4. Deep Learning :

↳ Usada em Redes com muitas camadas ocultas, destacando-se pela aprendizagem através de conjuntos de dados gigantes.

- Camadas iniciais detetam padrões básicos (arestas), camadas intermédias cobinam-nos em formas/texturas e camadas profundas reconhecem conceitos/objetos.



Outros paradigmas :

- **Transfer Learning**: Pré-treinar uma rede de forma geral para depois adap.
- **Reinforcement Learning**: Aprende a tomar decisões para aumentar a ^{taxa para uma} tarefa específica, recebendo recompensa.
- **Unsupervised Learning**: Gera + dados e aprende deles.