

Exemplo de Exame (Parte A)

Parte A:

1 – Considere o seguinte conjunto de variáveis categóricas adquiridas de um conjunto de 11 doentes:

Tabela 1: Dados relativos a 11 doentes.

| | | | | | | | | | | | |
|----------------------|-----|-----|-----|----|----|-----|-----|-----|-----|-----|-----|
| Hipertensão | S | S | S | S | S | N | S | S | N | N | S |
| Edema | S | S | N | N | S | N | S | S | S | S | S |
| Ritmo Cardíaco (BPM) | 150 | 120 | 80 | 67 | 88 | 56 | 67 | 90 | 96 | 78 | 130 |
| Glicémia (mg/dL) | 150 | 190 | 125 | 90 | 66 | 199 | 121 | 321 | 210 | 170 | 199 |
| HF Descompensado | S | S | S | S | N | N | N | S | S | S | S |

Assumindo que S="Sim", N="Não", considere que lhe é pedido que projete um preditor do risco de descompensação usando uma variável categórica (Hipertensão e Edema) e uma variável numérica (Ritmo cardíaco e Glicémia). Nesse contexto, responda às seguintes questões:

- Determine o valor Kruskal Lambda para as variáveis independentes Hipertensão e Edema relativamente à variável dependente HF Descompensação. Apresente todos os cálculos; não use implementações computacionais.
- Se tivesse de escolher uma das variáveis independentes categóricas como feature num classificador, qual usaria? Fundamente.
- Determine a relevância usando o score de Fisher das variáveis Ritmo Cardíaco e Glicémia. Apresente todos os cálculos (não deverá usar bibliotecas já definidas).

2 – Considere a série temporal presente na figura e tabela seguinte:

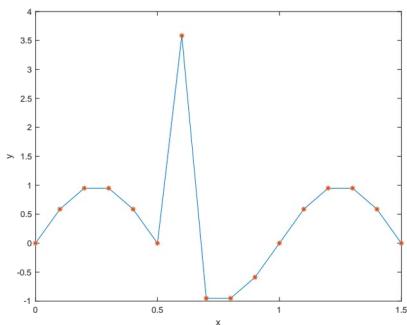


Tabela 2: Pontos (x,y) e da variável dependente "output".

| x | 0.0 | 0.1 | 0.2 | 0.3 | 0.4 | 0.5 | 0.6 | 0.7 | 0.8 | 0.9 | 1.0 | 1.1 | 1.2 | 1.3 | 1.4 | 1.5 |
|---|-----|-------|-------|-------|-------|-----|-------|---------|---------|---------|-----|-------|-------|-------|-------|-----|
| y | 0. | 0.587 | 0.951 | 0.951 | 0.587 | 0 | 3.585 | -0.9511 | -0.9511 | -0.5878 | 0 | 0.587 | 0.951 | 0.951 | 0.587 | 0.0 |

| | | | | | | | | | | | | | | | |
|--------|---|---|---|---|---|---|---|---|---|---|---|---|---|---|--|
| | 0 | 8 | 1 | 1 | 8 | | 5 | | | | 8 | 1 | 1 | 8 | |
| output | A | A | A | A | A | A | B | B | B | A | A | A | A | A | |

- a) Assumindo que os pontos são distribuídos segundo uma distribuição normal, determine os outliers da série; não use implementações computacionais.
- b) Use um processo autorregressivo (regressão linear) de dimensão 3 para imputar os outliers determinados em a). Apresente todos os cálculos e matrizes relevantes; não use implementações computacionais.

Parte B

3 – Pretende-se criar um modelo computacional para previsão do risco de insuficiência cardíaca (risco: alto, médio, baixo). Para isso, foi criada uma pequena base de dados envolvendo 200 sujeitos, onde foram recolhidos dados para os seguintes atributos: paciente tem doença arterial coronariana (CAD: sim, não), faixa etária (G1: < 45 anos; G2: ≥ 45 e < 65; G3: ≥ 65) e nível de pressão arterial do paciente (BPL: baixa, media, alta).

- a) A tabela seguinte representa uma amostra do conjunto de treino, contendo os dados de apenas 12 sujeitos. Na construção de um classificador OneR, que atributo seria selecionado, que regras seriam obtidas e que taxa de erro seria alcançada? Apresente os cálculos necessários.

| CAD | Age Group | BPL | Heart Failure |
|-----|-----------|-----|---------------|
| N | G1 | B | B |
| N | G1 | A | B |
| S | G1 | B | B |
| N | G2 | M | B |
| N | G2 | A | M |
| S | G1 | A | M |
| S | G2 | M | M |
| N | G3 | B | B |
| N | G3 | A | A |
| S | G2 | A | A |
| S | G3 | M | A |
| S | G3 | A | A |

- b) Agora imagine que um classificador Naive Bayes foi utilizado no mesmo conjunto de treino. Como é que esse modelo classificaria uma nova amostra (CAD = N; Faixa Etária = G1; BPL = M)? Apresente os cálculos necessários.
- c) No cenário descrito na alínea b), quão confiante poderia estar em relação à classificação proposta? Justifique a sua resposta quantitativamente.
- d) Se utilizasse um Multi-Layer Perceptron, como definiria a camada de saída (número de neurónios, tipo de funções de ativação e representação da saída alvo – target output)? Justifique as suas decisões.

4 – Um dos principais hiperparâmetros das máquinas vetoriais de suporte (SVM) é o parâmetro Cost. Explique como funciona (em termos gerais) e o seu impacto em termos de enviesamento (bias) e variância.